

UNIVERZA V LJUBLJANI

FAKULTETA ZA ELEKTROTEHNIKO

Poročilo - Vaja4
Nevronske mreže in učenje s PSO
Inteligentni sistemi za podporo odločanju

Martin Knap, 64180369

Mentor: prof. dr. Igor Škrjanc

Asistent: doc. dr. Dejan Dovžan

Ljubljana, 28. 4. 2019

Kazalo

1	Definicija naloge	2
2	Umetne nevronske mreže	2
2.1	Zgradba	2
3	PSO	2
3.1	Diagram poteka	4
4	Rezultati	5
4.1	Rezultati učenja z vgrajeno funkcijo	5
4.2	Rezultati učenja s PSO optimizacijo	6
5	Komentar in zaključek	7

Slike

1	Perceptron [2].	2
2	Uporabljena nevronska mreža.	2
3	Diagram poteka algoritma PSO.	4
4	Konfuzijska matrika za učno množico - train	5
5	Konfuzijska matrika za testno množico - train	5
6	Konfuzijska matrika za učno množico - PSO.	6
7	Konfuzijska matrika za testno množico - PSO.	6

Tabele

1	Primerjava napak.	6
---	---------------------------	---

1 Definicija naloge


Pri tej vaji je naša naloga zgraditi sistem za prepoznavo raka dojke in sicer na podlagi podatkov z 569 meritvami, od tega ima vsaka meritev 30 parametrov, ki kažejo na maligno ali benigno rakavo tvorbo. Sistem za prepoznavo je potrebno zgraditi z uporabo nevronske mreže, kateri je potrebno določiti uteži na dva načina. Prvi način je uporaba integrirane rešitve iz Matlab-ove knjižnice za nevronske mreže, drugi način pa je PSO optimizacija (angl.: *Particle Swarm Optimization*).

2 Umetne nevronske mreže

Umetne nevronske mreže ali nevronske mreže so računski sistemi, ki jemljejo navdih za delovanje iz bioloških nevronskih mrež, te pa so gradnik živalskih možganov. Nevronska mreža ni algoritem temveč je konstrukcija, ki omogoča vzajemno delovanje algoritmov strojnega učenja tako, da procesirajo kompleksnejše podatkovne strukture. Te sistemi se učijo opravljati specifično vrsto opravila tako, da jim podajamo primere v obliki vhodno-izhodnih parov (učna množica).


2.1 Zgradba

Nevronske mreže tvorijo trije nivoji perceptronov in sicer vhodni, skriti ter izhodni nivo. Perceptron je računska celica mreže, katerega izhod je vrednost aktivacijske funkcije pri neki linearni kombinaciji vhodov (Slika 1). Vhodni nivo mreže je brez aktivacijskih funkcij. Jedro nevronske mreže pa predstavlja struktura skrite plasti. Učenje v smislu nevronske mreže pomeni ocena uteži povezav med vhodno in skrito plastjo tako, da dobimo željene rezultate. Naša naloga pri tej laboratorijski vaji je ocena prav teh uteži s PSO optimizacijo ter primerjava z integrirano rešitvijo.



Slika 1: Perceptron [2].

Uporabljena nevronska mreža je usmerjenega tipa (angl.: *Feedforward*), to je brez povratnih povezav. Sama mreža ima 30 vhodov ter 3 perceptrone v skriti plasti. To nanese na 97 uteži med vhodno in skrito plastjo, ki jih je potrebno optimalno nastaviti.



Slika 2: Uporabljena nevronska mreža.

3 PSO

Optimizacija z roji decev ali PSO je stohastična računska metoda, ki išče minimum kriterijske funkcije s pomočjo množice delcev, ki so kandidati za rešitev problema. Delec je točka v parameterskem prostoru problema dimenzije d in ga lahko zapišemo kot $\underline{\theta}_i = [\theta_{i1}, \dots, \theta_{id}]$. Parametri delca so sprva določeni naključno potem pa se iterativno spreminja njihov položaj. Vsak delec ima položaj $\underline{\theta}_i$ ter hitrost $\Delta\theta_i$ (sprememba položaja). Sprememba položaja delca je odvisna od vrednosti vektorja parametrov pri

najvišji funkciji kvalitete \underline{p}^{best} za ta določen delec in z vrednostjo vektorja parametrov z najvišjo funkcijo kvalitete v celotni populaciji (roju) delcev \underline{g}^{best} .

Z vsako iteracijo se posameznemu delcu popravi položaj po sledeči enačbi - PSO s faktorjem omejitve:

$$\Delta \underline{\theta}_i = \kappa(\Delta \underline{\theta}_i + c_1 rand1 * (\underline{p}_i^{best} - \underline{\theta}_i) + c_2 rand2 * (\underline{g}^{best} - \underline{\theta}_i)) \quad (1)$$

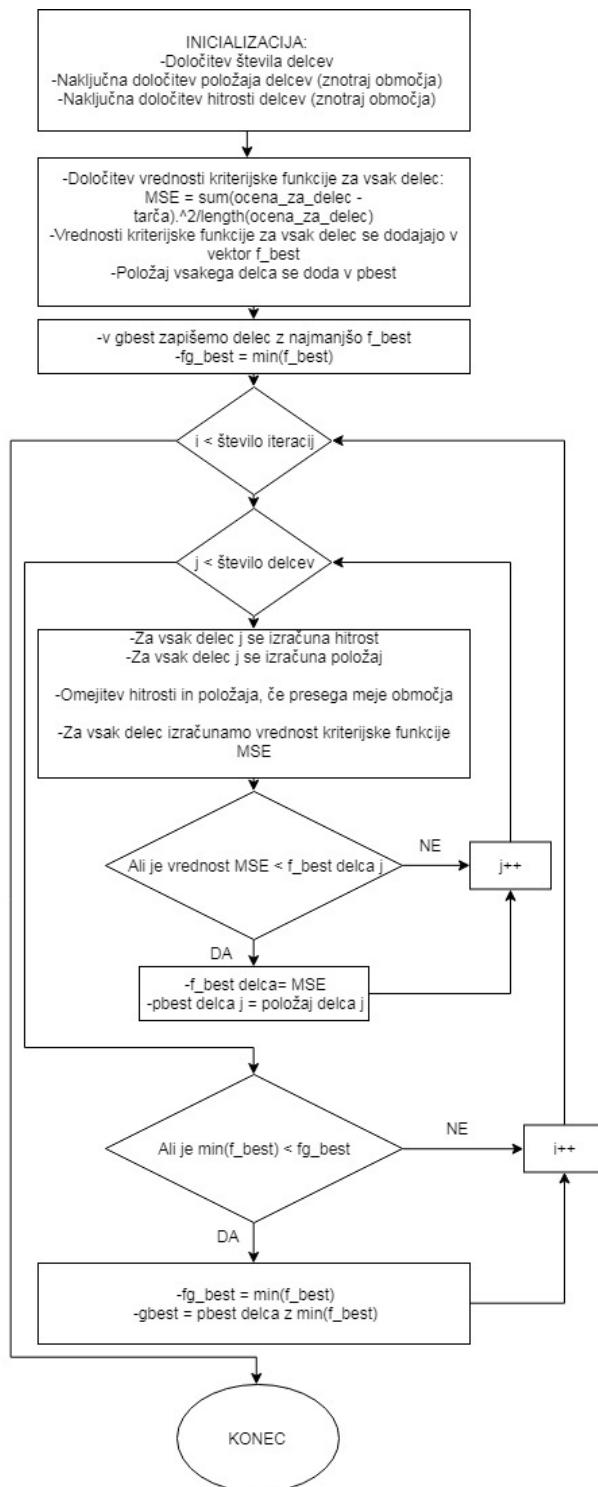
$$\underline{\theta}_i = \underline{\theta}_i + \Delta \underline{\theta}_i \quad (2)$$

Tu sta $rand1$ in $rand2$ vektorja naključnih števil znotraj območja parametrov, njuna dolžina pa je enaka številu uteži mreže. Konstanta κ pa je definirana kot:

$$\kappa = \frac{2}{|2 - \phi - \sqrt{\phi(\phi - 4)}|}, \phi = c_1 + c_2 > 4 \quad (3)$$

3.1 Diagram poteka

Na spodnji sliki je predstavljen diagram poteka algoritma. Izhod algoritma je optimalni položaj delca oziroma optimalen set uteži mreže \underline{g}^{best} .




Slika 3: Diagram poteka algoritma PSO.

4 Rezultati


Vseh meritev za raka dojke je 569 od tega je malignih tumorjev 212, benignih pa 357. Učno množico tvori 140 meritev malignih tumorjev in 236 izmerkov benignih tumorjev. Preostanek meritev sestavlja testno množico.

4.1 Rezultati učenja z vgrajeno funkcijo

Za določanje uteži mreže je bila najprej uporabljena integrirana rešitev (Matlab: `train`) za katero stoji optimizacijska metoda najmanjših nelinearnih kvadratov Levenberg-Marquardt.




Slika 4: Konfuzijska matrika za učno množico - `train`.




Slika 5: Konfuzijska matrika za testno množico - `train`.

4.2 Rezultati učenja s PSO optimizacijo



Slika 6: Konfuzijska matrika za učno množico - PSO.



Slika 7: Konfuzijska matrika za testno množico - PSO.

Tabela 1: Primerjava napak.

	train	PSO
MSE učna množica	0.02619	0.02054
MSE testna množica	0.04439	0.03856

5 Komentar in zaključek

Če pogledamo konfuzijsko matriko (Slika 4) za nevronske mreže dobljeno z vgrajeno funkcijo pri učni množici vidimo, da smo od 236 benignih tvorb 9 primerov identificirali napačno, v primeru malignih pa le enega od 140. Ta rezultat precej dober, kot kaže tudi MSE (*Mean Squared Error*) cenilka z vrednostjo 0.02619. Ta nevronska mreža nam na testni množici vrne pričakovano slabše rezultate (Slika 5). Med benignimi tvorbami smo jih 8.3% prepoznali napačno, med malignimi pa 1.4%. MSE napaka v tem primeru znaša 0.04439.

V primeru nevronske mreže, ki smo ji uteži določili z PSO algoritmom lahko opazimo, da smo z učno množico dobili izjemne rezultate, saj MSE napaka znaša zgolj 0.02054. Le 1.3% benignih tvorb smo prepoznali napačno in 3.6% v primeru malignih (Slika 6). Na testni množici so rezultati ponovno pričakovano slabši z MSE napako 0.03856. V tem primeru smo 5% benignih identificirali napačno ter 2.8% malignih (Slika 7).

V tem primeru se je nevronska mreža z utežmi pridobljenimi preko PSO optimizacije izkazala za boljšo v smislu napake. Časovno je algoritem neprimerljivo počasnejši od vgrajene rešitve. Potrebno pa je poudariti, da PSO ne omogoča vedno globalnega optimuma ter da so rezultati mnogokrat tudi slabši od mreže, ki ima uteži določene z funkcijo `train`. Vgrajena rešitev daje bolj konsistentne rezultate v smislu napake.

V primeru, da se v perceptroni skrite in izhodne plasti uporabi linearno aktivacijsko funkcijo dobimo sledeče rezultate. Z mrežo uteženo s `train` dobimo malenkost slabše rezultate od tiste, ki uporablja sigmoidno aktivacijsko funkcijo. V primeru mreže z utežmi iz PSO optimizacije pa dobimo popolnoma neuporabne rezultate.

Literatura

- [1] Igor Škrjanc *Inteligentni sistemi za podporo odločanju*. Ljubljana, 2016
- [2] <https://stackoverflow.com/questions/40537503/deep-neural-networks-precision-for-image-recognition-float-or-double>.