

UNIVERZA V LJUBLJANI

FAKULTETA ZA ELEKTROTEHNIKO

Poročilo - Vaja5
Razvoj nelinearnega modela

Inteligentni sistemi za podporo odločanju

Martin Knap, 64180369

Mentor: prof. dr. Igor Škrjanc

Asistent: doc. dr. Dejan Dovžan

Ljubljana, 13. 5. 2019

Kazalo

1	Definicija naloge	2
2	Model pridobljen z nevronske mreže	2
3	Mehki model	3
4	Validacija in primerjava modelov	5
5	Komentar in zaključek	7

Slike

1	Identifikacijski signal $u(k)$.	2
2	Odziv dejanskega sistema $y(k)$ na identifikacijski signal.	2
3	Uporabljena nevronska mreža.	3
4	Psevdokoda GK [1].	3
5	Validacijski signal.	5
6	Primerjava med odzivom dejanskega modela in modela nevronske mreže.	5
7	Primerjava med odzivom dejanskega modela in mehkega modela.	6
8	Primerjava vseh odzivov.	6
9	Histogram napake za model pridobljen z nevronske mreže.	7
10	Histogram napake za mehki model.	7

Tabele

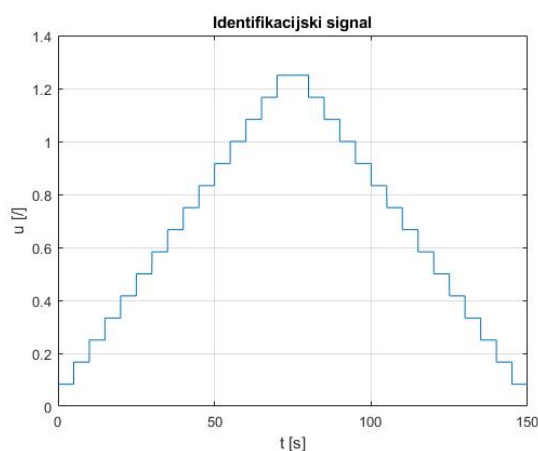
1	Primerjava napak.	7
---	-------------------	---

1 Definicija naloge

Pri tej vaji je naša naloga razviti simulacijski model procesa, bolj točno helio-žerjava (*angl.: helio-crane*). To je nihalo, ki ima na koncu ročice motor s propelerjem. Naloga je razdeljena v dva dela. Prvi del zahteva izdelavo modela z uporabo nevronske mreže, drugi del pa zahteva razvoj mehkega modela. Za konec pa je potrebno oba modela primerjati.

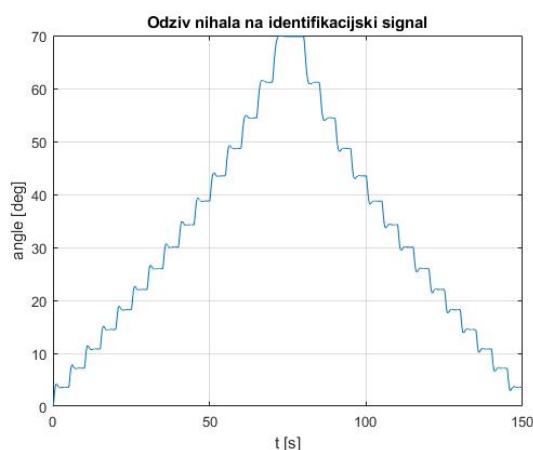
2 Model pridobljen z nevronske mreže

Sprva je bilo potrebno ustvariti nelinearen model z uporabo nevronske mreže. Orodja za tvorbo in učenje pa nam nudi Matlab z vgrajenimi funkcijami. Na začetku je bilo potrebno ustvariti vhodni signal za identifikacijo procesa. Vhodni identifikacijski signal $u(k)$ (slika 1) je sestavljen iz večjih stopnic, ki helio-žerjav krmilijo od lege v mirovanju (kot 0°) do končne lege (kot cca. 70°).



Slika 1: Identifikacijski signal $u(k)$.

Na ta način dobimo informacijo o dinamskih karakteristikah sistema v celotnem delovanem območju. Signal vstavimo v priloženo funkcijo *heliocrane.p*, ki nam vrne odziv dejanskega sistema $y(k)$ (slika 2).



Slika 2: Odziv dejanskega sistema $y(k)$ na identifikacijski signal.


Sedaj imamo vse podatke za tvorbo učne množice mreže UM . Slednjo bomo tvorili iz enkrat in dvakrat zakasnenih signalov izhoda in enkrat zakasnjenegega izhoda helio-žerjava. To storimo zato, ker gre za dinamski sistem 2. reda (fizično nihalo: $J \ddot{Y}(t) + b \dot{Y}(t) + m g l Y(t) = M(t)$) v diferenčni obliki.

$$UM = [\underline{u}(k-1), \underline{y}(k-1), \underline{y}(k-2)] \quad (1)$$

Tarče T učne množice pa predstavljajo trenutni izhodi.

$$T = \underline{y}(k) \quad (2)$$

Nevronska mreža, ki jo bomo uporabili za tvorbo modela ima štiri vhodne perceptrone, štiri perceptrone v skriti plasti s sigmoidno aktivacijsko funkcijo in en izhodni perceptron z linearno aktivacijsko funkcijo (slika 3).



Slika 3: Uporabljen nevrnska mreža.

3 Mehki model

Sledila je tvorba mehkega modela po metodi Takagi-Sgueno. Najprej je bilo potrebno izvesti rojenje po metodi Gustafson-Kessel za določanje centrov \underline{v} in deviacij $\underline{\sigma}$ rojev vhodno-izhodnega para podatkov \underline{X} . Cilj je delitev celotne množice podatkov na podmnožice, ki vsebujejo elemente z največjo podobnostjo.

$$\underline{X} = [\underline{u}(k), \underline{y}(k)] \quad (3)$$

Psevdokoda algoritma je prikazana na spodnji sliki.

- 1: Inicializacija števila rojev c
- 2: Izbira uteži η
- 3: Izbira tolerančnega praga za zaključek iteracije min_{impro} in izbira maksimalnega števila iteracij r_{max}
- 4: Inicializacija matrike pripadnosti z naključnimi vrednostmi $U^0 \in M$
- 5: Izbira začetne vrednosti faktorja $\rho_i^0 = 1, i = 1, \dots, c$
- 6: **repeat**
- 7: Izračun središč rojev: $\underline{v}_i^{(r)} = \frac{\sum_{k=1}^n (\mu_{ik}^{(r)})^\eta \underline{x}(k)}{\sum_{k=1}^n (\mu_{ik}^{(r)})^\eta}, i = 1, \dots, c$
- 8: Izračun mehke kovariančne matrike: $\underline{\Sigma}_i = \frac{\sum_{k=1}^n (\mu_{ik}^{(r-1)})^\eta (\underline{x}(k) - \underline{v}_i) (\underline{x}(k) - \underline{v}_i)^T}{\sum_{k=1}^n (\mu_{ik}^{(r-1)})^\eta}, i = 1, \dots, c$
- 9: Izračun matrike notranjega produkta: $\underline{F}_i = \left(\rho_i^{(r-1)} |\underline{\Sigma}_i| \right)^{\frac{1}{m}} \underline{\Sigma}_i^{-1}, i = 1, \dots, c$
 $\rho_i^{(r)} = |\underline{F}_i|, i = 1, \dots, c$
- 10: Izračun razdalj: $d_{ik}^2 = \left(\underline{x}(k) - \underline{v}_i^{(r)} \right)^T \underline{F}_i \left(\underline{x}(k) - \underline{v}_i^{(r)} \right), i = 1, \dots, c, k = 1, \dots, n$
- 11: Izračun matrike pripadnosti: $\mu_{ik}^{(r)} = \frac{\frac{1}{d_{ik}^w}}{\sum_{j=1}^c \frac{1}{d_{jk}^w}}, w = \frac{2}{\eta-1}$
- 12: **until** $\|\underline{U}^{(r)} - \underline{U}^{(r-1)}\|_\infty < min_{impro}$ ali $r \geq r_{max}$

Slika 4: Psevdokoda GK [1].

Z znanimi centri ter deviacijami se sedaj lahko lotimo modeliranja lineranih nevro-mehkih modelov. Vsak nevron tega modela realizira en lokalni linearni model. Vsakemu linearnemu modelu pripada veljavnostna funkcija, ki definira področje veljavnosti lokalnega linearnega modela. Število teh funkcij M je enako številu prej izbranih rojev. Veljavnostne funkcije Φ_i so normirane tako, da velja:

$$\sum_{i=1}^M \Phi_i(\underline{u}) = 1 \quad (4)$$

Izhod mehkega modela je:

$$\hat{y} = \sum_{i=1}^M (w_{i0} + w_{i1}u_1 + \dots + w_{ip}u_p) \Phi_i(\underline{u}) \quad (5)$$

Izhod modela je tako izračunan kot utežena vsota lokalnih linearnih modelov, kjer so veljavnostne funkcije interpretirane kot uteži, ki so odvisne od delovne točke.

Uteži w_{ij} so linearni parametri mreže, veljavnostne funkcije so pa normirane Gauss-ove funkcije $\mu_i(\underline{u})$ z centri \underline{v} in deviacijami $\underline{\sigma}$, ki smo jih določili z GK metodo.

$$\Phi_i(\underline{u}) = \frac{\mu_i(\underline{u})}{\sum_{j=1}^M \mu_j(\underline{u})} \quad (6)$$

$$\mu_i(\underline{u}) = \exp\left(-\frac{1}{2}\left(\frac{(u_1 - v_{i1})^2}{\sigma_{i1}^2} + \dots + \frac{(u_p - v_{ip})^2}{\sigma_{ip}^2}\right)\right) \quad (7)$$

Določanje parametrov podmodelov w_{ij} izvedemo z metodo uteženih najmanjših kvadratov, kjer imata regresijska matrika \underline{X}_i in utežna matrika \underline{Q}_i sledečo obliko.

$$\underline{X}_i = [1, \underline{u}(k-1), \underline{y}(k-1), \underline{y}(k-2)] \quad (8)$$

$$\underline{Q}_i = \begin{bmatrix} \Phi_i(u(1)) & 0 & \dots & 0 \\ 0 & \Phi_i(u(2)) & & \vdots \\ \vdots & & \ddots & 0 \\ 0 & \dots & 0 & \Phi_i(u(N)) \end{bmatrix} \quad (9)$$

Uteži za vsak podmodel dobimo na sledeč način.

$$\underline{w}_i = (\underline{X}_i^T \underline{Q}_i \underline{X}_i)^{-1} \underline{X}_i^T \underline{Q}_i \underline{y}(k) \quad (10)$$

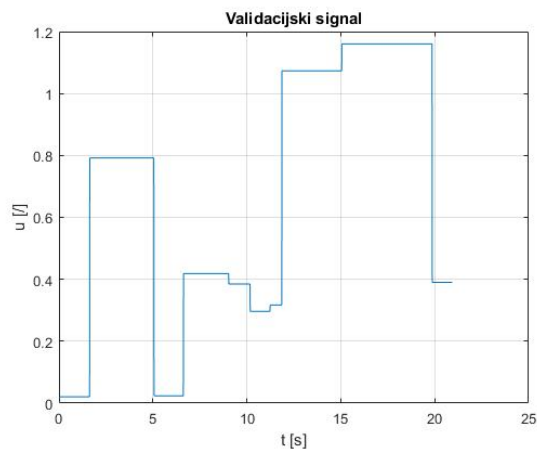
Izhod lokalnega modela pa je:

$$\hat{y}_i = \underline{X}_i \underline{w}_i \quad (11)$$

Na ta način izračunamo ocene za vse podmodele.


4 Validacija in primerjava modelov

Validacija je bila izvedena z naključnim signalom v območju vzbujanja helio-žerjeva (slika 5).



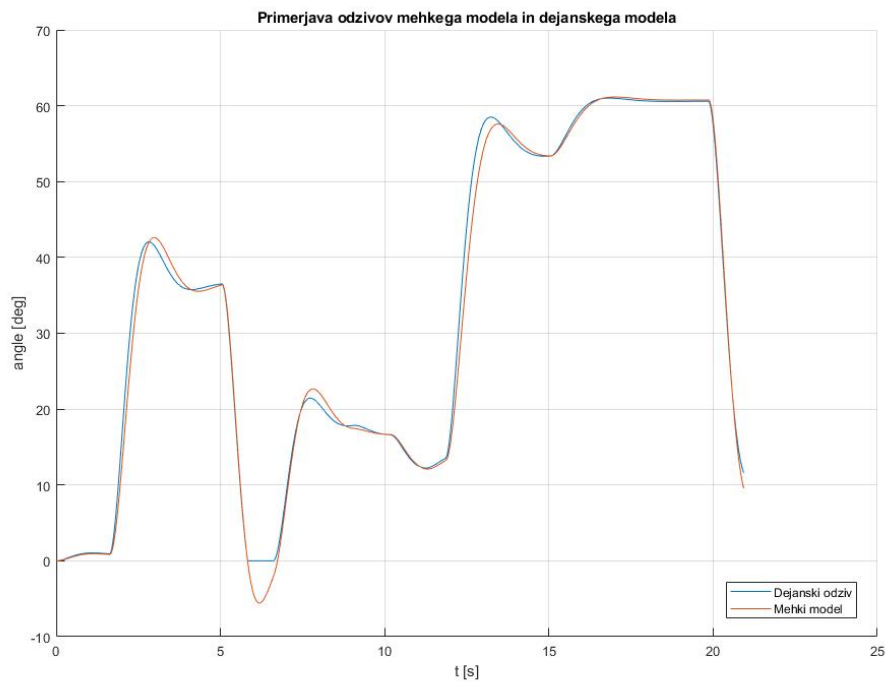
Slika 5: Validacijski signal.

Najprej je bila izvedena primerjava med ozivom dejanskega modela in modela nevronske mreže (slika 6).




Slika 6: Primerjava med odzivom dejanskega modela in modela nevronske mreže.

Sledila je primerjava med dejanskim odzivom ter odzivom mehkega modela.




Slika 7: Primerjava med odzivom dejanskega modela in mehkega modela.

In še primerjava vseh odzivov.

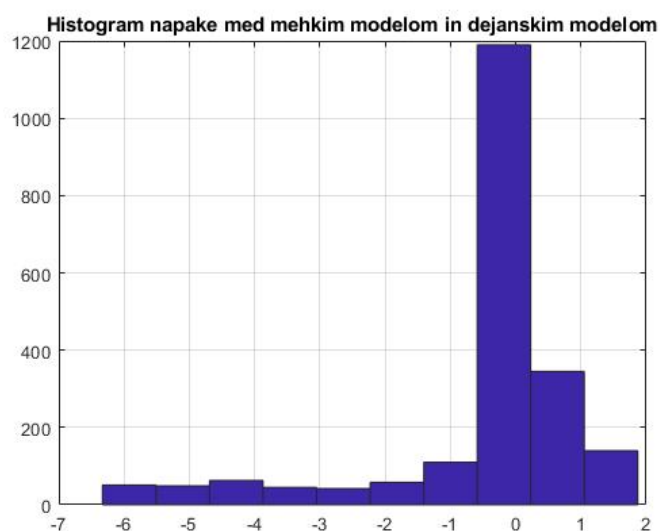


Slika 8: Primerjava vseh odzivov.

Izrisana sta bila tudi histograma napake:



Slika 9: Histogram napake za model pridobljen z nevronske mreže.



Slika 10: Histogram napake za mehki model.

Za primerjavo kavitete je bila izračunana tudi MSE (angl.: *Mean Squared Error*) napaka.

Tabela 1: Primerjava napak.

	NN model	Mehki model
MSE	0.5295	2.8232

5 Komentar in zaključek

Z ozirom na pridobljene rezultate lahko sklepamo, da je model ustvarjen z nevronske mreže bolj točen. Podlaga za ta skelp je graf kot tudi MSE napaka. Če primerjamo histograma napake opazimo tudi manjši raztros napak ter manjše število večjih odstopkov. Potrebno pa je omeniti, da Matlab-ova funkcija za učenje ni vedno določila tako dobrih uteži. Včasih je bilo učenje popolnoma neuspešno.

Če si ogledamo še rezultate mehkega modela vidimo, da je odziv modela manj točen. Potrebno pa je omeniti, da je bil proces določanja modela pri večkratni ponovitvi programa vedno uspešen. Ta trditev za model nevronske mreže odpade.

Literatura

- [1] Igor Škrjanc, *Inteligentni sistemi za podporo odločanju*. Ljubljana, 2016
- [2] Andrej Zdešar, Otta Cerman, Dejan Dovžan, Petr Hušek & Igor Škrjanc, *Fuzzy Control of a Helio-Crane*.